

Methods for Cleaning Qualitative Research Data

(How can Python and AI help Text Mining work)

Presented by SHANG Wenxuan

2026.05.14

Structure

1. The Problem
2. OCR Methods
3. Text Denoising
4. AI Purpose and Boundary

1. The Problem

1.1 About Text Mining and Coding

- It refers to systematic extraction of core issues/expressions from EIA materials.
- Then, with three-level coding (open, axial, selective), transform textual data into structured analytical framework.
- Network visualization and stakeholder dynamics.
- Nvivo is a frequently used software for this qualitative research.

1.2 File Types

- (1) Printed text with a text layer (pre-processed via OCR, Word to PDF) , [which can be recognized directly by Nvivo.](#)
- (2) Printed text without a text layer (image) – [Cloud Vision API](#)
- (3) Handwritten text or mixed text without a text layer (image) – [Gemini API \(Gemini 3 Flash/Gemini 2.5 Flash Lite\)](#)

1.3 Nvivo characteristics and file corresponding conditions (1)

- Nvivo do not have OCR (Text Recognition) tools.
- For qualitative research and text mining, text must be recognized.

What does this mean?

1.3 Nvivo characteristics and file corresponding conditions (1)

- Nvivo do not have OCR (Text Recognition) tools.
- For qualitative research and text mining, text must be recognized.

What does this mean?

Region Coding cannot be used. Because we need automated word frequency analysis, cross-text search in the future.

Therefore,

- (1) Printed text with a text layer – Nvivo no problem.
- (2) Printed text without a text layer – Need OCR
- (3) Handwritten text or mixed text without a text layer – Need intelligent OCR

1.3 Nvivo characteristics and file corresponding conditions (2)

- **Text noise** can interfere with NVIVO

For example,

- (1) Word Frequency Pollution (High-frequency chatter: “page”; Header Title……)
- (2) Semantic Disruption (Forced Line Break; Page numbers appear in the sentence……)

Solution?

- 1. Transform into TXT file**, whatever the file types (1)(2) or (3) I just mentioned. – PDF and WORD have format, while TXT is pure.
- 2. Text denoise with Python**, delete those nonsense words.

1.4 The Problem Conclusion

– What should I do?

- (1) Printed text with a text layer – Transform into txt file and denoise with Python
 - (2) Printed text without a text layer – OCR into txt and denoise
 - (3) Handwritten text or mixed text without a text layer – AI OCR into txt and denoise
-
- In conclusion, Three Steps:
 1. OCR: (2) & (3) with different OCR tools and output TXT;
 2. Transform (1) into TXT with Python only;
 3. Denoise (1) (2) (3) with Python only.

2. OCR Methods

2.1 AI OCR

- Traditional OCR tools cannot recognize (scribbled) handwriting. Its work is based on pixel and “checking the dictionary”.
- However, AI can competent this job.
- Why? HW images traning, Extract essential features; And most important: Understanding the context.

2.2 Python Supported AI OCR (File Type 3)

- Direct AI OCR has a trouble: You cannot make screen print for thousands of times and upload to AI one by one.
- But Python is naturally suited for repetitive work.

- **The approach:**

Write a Python program which can automatically call Gemini to do this OCR job for thousands loops (until the last page).

How to call Gemini in Python? API!

Application Programming Interface:

ソフトウェアアプリケーション間の相互通信、データ交換、および機能統合を行うための、あらかじめ定義された一連の規則とプロトコル

2.2 Python Supported AI OCR: Preparation

- Preparations

(All powered by Google, no download required.)

1. Sign in **Google Cloud Console** and create **a new project**.
2. **Activate your full account** in Cloud (upload a credit card, and you will get 300 USD gift card for multi uses other than Gemini.)
3. In **Google AI Studio**, **Create** your own **API key** and activate its “Gemini API” and “Cloud Vision API” function. Keep Your API Key Secret.
4. Upload your target files into **Google Drive**.
5. Ask Claude and get the **Python program code**, paste it into **Google Colab** (an online and AI supported development platform, no domestic Python needed) and **run it**. The output file will appear in Drive.

2.2 Python Supported AI OCR: Result

第 26 页

「淡水河北側沿河平面道路工程（淡水河北側沿河快速道路第一期工程替代方案）環境影響評估報告書初稿」專案小組初審會議意見表

單位：市議員 姓名：蔡榮偉

前次意見續審：□ 補正回應情形已符規定或足供審查判斷所需資訊。

□ 前次意見尚須補正，補正意見如下：

一、釐清與排除，難以對林

1. 已透過會勘釐清 1 公分問題。

2. 排除一些替代方案。

① 台2線高架。

② 台2線拓寬。

二、交通是市市相連，沒有對誰有利，或 双北共同共榮，形成生活圈，双北應一起共同來解決市民需求的問題。

三、淡山從 7-8 萬人，變成現在的 17 萬多人，需要好的交通。

四、關渡大橋不宜以此銜接。

又，謝謝環保人士的監督，讓本道路能

註1：請填寫意見單並於會後交予本案承辦人（楊智凱，電話：(02)2311-7722 轉 2742，傳真：(02)2331-2958，E-mail: ckyang@epa.gov.tw），俾便彙整。

註2：請儘可能針對前次「意見」之回覆，延續表達意見，確認開發單位補正回應情形是否已符規定或足供審查判斷所需資訊，以利意見有效收斂聚焦。

越修正越好。

「淡水河北側沿河平面道路工程（淡水河北側沿河快速道路第一期工程替代方案）環境影響評估報告書初稿」專案小組初審會議意見表

單位：市議員 姓名：蔡榮偉

前次意見續審：□ 補正回應情形已符規定或足供審查判斷所需資訊。

□ 前次意見尚須補正，補正意見如下：

一、釐清與排除，難以對林
1. 已透過會勘釐清 1 公分問題。
2. 排除一些替代方案。
① 台2線高架。
② 台2線拓寬。

二、交通是市市相連，沒有對誰有利，或 双北共同共榮，形成生活圈，双北應一起共同來解決市民需求的問題。

三、淡水從 7-8 萬人，變成現在的 17 萬多人，需要好的交通。
四、關渡大橋不宜以此銜接。
又，謝謝環保人士的監督，讓本道路能

註1：請填寫意見單並於會後交予本案承辦人（楊智凱，電話：(02)2311-7722 轉 2742，傳真：(02)2331-2958，E-mail: ckyang@epa.gov.tw），俾便彙整。

註2：請儘可能針對前次「意見」之回覆，延續表達意見，確認開發單位補正回應情形是否已符規定或足供審查判斷所需資訊，以利意見有效收斂聚焦。

越修正越好。

2.2 Python Supported AI OCR: Program (from Claude)

```
• !pip install -q google-genai pymupdf pillow
• from google.colab import drive
• drive.mount('/content/drive')
• from google import genai
• import fitz
• from PIL import Image
• import io
• import time
• import os
• # ===== 只需修改这两行 =====
• API_KEY = "Your_Own_API_Key"
• PDF_PATH = "Your_PDF_Path"
• # =====
• OUTPUT_PATH = "/content/drive/MyDrive/ocr_结果.txt"
• # 确认文件存在
• print("文件存在 :", os.path.exists(PDF_PATH))
• print("文件大小 :", os.path.getsize(PDF_PATH), "字节")
• client = genai.Client(api_key=API_KEY)
• doc = fitz.open(PDF_PATH)
• total_pages = len(doc)
• print(f"共 {total_pages} 页, 开始识别...")
• results = []
• for i, page in enumerate(doc):
•     print(f"处理第 {i+1}/{total_pages} 页...", end=" ")
•     pix = page.get_pixmap(dpi=200)
•     img = Image.open(io.BytesIO(pix.tobytes("png")))
•     success = False
•     for attempt in range(3):
•         try:
•             response = client.models.generate_content(
•                 model="gemini-flash-latest",
•                 contents=[
•                     img,
•                     "请识别图片中所有文字，包括印刷体和手写体。手写部分请尽力辨认，不确定的字用【？】标注。按照原文的段落结构输出，不要添加任何解释。"
•                 ]
•             )
•             text = response.text
•             print(f"✓ {len(text)} 字")
•             success = True
•             break
•         except Exception as e:
•             if attempt < 2:
•                 print(f"重试中...", end=" ")
•                 time.sleep(15)
•             else:
•                 text = f"[识别失败: {e}]"
•                 print(f"X 失败")
•     results.append(f"{text[:*50]}第 {i+1} 页{text[*50]*n}")
•     time.sleep(3) # 每页间隔3秒

• with open(OUTPUT_PATH, "w", encoding="utf-8") as f:
•     f.writelines(results)

• print(f"完成！结果保存至: {OUTPUT_PATH}")
```

Step 1 ツールの準備

PDF・画像・AI 用ライブラリをインストール

Step 2 Google Drive のマウント

クラウド上の研究資料へのアクセスを許可
ツールをインストールする

Step 3 パラメータ設定

API キー、PDF パス、出力先を指定

Step 4 PDF の読み込み

ファイルを開き、総ページ数を取得

Step 5 ページごとの処理(コアループ)

- ① 現在のページを画像に変換
- ② 画像と指示を AI に送信
- ③ 認識されたテキストを受信
- ④ 失敗時は最大 3 回まで再試行

212 ページ繰り返し


Step 6 結果の保存

全ページの結果を .txt ファイルに集約


2.2 Python Supported AI OCR: Costs

概观

API 请求总数




API 错误总数




生成内容和 Live API

每个模型的输入 token 数



每个模型的输出 token 数



每个模型的请求数



Overview

[Paid account](#)

[Manage billing account](#)

[Billing account overview](#)

[Payment overview](#)

Your total cost (May 1 - 14, 2026)

Last 7 days

Current month

Cost
¥400

—

Savings
¥0

=

Total cost
¥400

[View details](#)

Forecasted total cost

Available once there is enough usage



[View details on Reports](#)

2.3 Printed text OCR without text layer (File Type 2)

- Similar with Gemini API: Write a Python program and call Cloud Vision API.
- **Cloud Vision API**: Trained with CNN (an AI method), good at HW recognition. But it does not have an intelligent “brain”, therefore it cannot understand the context.
- Advantage: Very cheap and fast, Free limits every month, Gift card is usable.

2.4 Printed text with a text layer (File Type 1)

- The fastest and easiest process. Totally free.
- With Python (pdftotext) program only, from PDF to TXT.
- Accuracy Rate 100%

3. Text Denoising

3.1 What files do we have at this point?

- (1) Printed text with a text layer – Changed into TXT by Python
- (2) Printed text without a text layer – Changed into TXT by Cloud Vision API
- (3) Handwritten text or mixed text without a text layer – Changed into TXT by Gemini API
- Therefore, we get only one new type:
 - 1. TXT files (with noise)
- Next Step:
 - Text Denoise.

3.2 What is Text Noise?

- 1. Line Break: A whole sentence could be disrupted.
- 2. Page Number: (1) May appear in a sentence when copy, (2) and may influence word frequency statistic with fixed words “page number”
- 3. Duplicate title: May influence word frequency

得此通知：經環保專家小組會議 107.8.23 初審
發言單 (發言人：環境法律協會理事長張登尹律師)

6. 依開發行為環境評估條例 28 條規定，開發單位應先
查明開發行為基地是否位於環境敏感地區。基地
不得位於相關法律所禁止開發利用之地區，位於
相關法律所限制開發利用之地區，應不得違反該
法令之限制規定。據查之，開發單位於本市府及
環保局核准開發計畫前，應注意基地所定之土地使用
限制。

二、系爭淡水河系重要濕地範圍，係指其位於自桐林自然
保留區，淡水河系重要濕地(國家級)。

5. 依濕地保護法第 20 條規定，申請開發行為重要濕地
範圍內之土地，應先經環保局核准開發計畫，並
經開發單位對重要濕地評估，開發行為對重要
濕地(國家級)範圍內之土地，應先經環保局核准
開發計畫，並經開發單位對重要濕地評估。

第 34 頁

淡水河系重要濕地評估小組會議 107.8.23 初審
發言單 (發言人：環境法律協會理事長張登尹律師)

1. 依開發行為環境評估條例之規定，開發單位應先
查明開發行為基地是否位於環境敏感地區。基地
不得位於相關法律所禁止開發利用之地區，位於
相關法令所限制開發利用之地區，應不得違反該
法令之限制規定。據查之，開發單位於新北市政府
環保局核准開發計畫前，應注意基地所定之土地使用
限制。

2. 系爭淡水河系重要濕地範圍，係指其位於自桐林自然
保留區，淡水河系重要濕地(國家級)。

3. 依濕地保護法第 20 條規定，各級政府於重要濕地
或已納入自然保留區範圍之其他濕地及周邊環境
開發計畫或開發行為時，應先經環保局核准開發計
畫，並經開發單位對重要濕地評估，開發行為對重
要濕地(國家級)範圍內之土地，應先經環保局核准
開發計畫，並經開發單位對重要濕地評估。

p. 1

3.3 How to Denoise?

- Python Only, Totally Free, No AI, API and Credit Card needed.

```
# === 第 3 步: 定义噪音过滤规则 ===
def is_noise_line(line):
    """判断一行是否是要剔除的噪音"""
    line = line.strip()
    if not line:
        return True
    # 单独页码 ("1-1", "第1頁 共5頁", "- 1 -")
    if re.match(r'\d+[\-\-]\d+$', line):
        return True
    if re.match(r'第\s*\d+\s*[頁页]\s*共?\s*\d*\s*[頁页]?$', line):
        return True
    if re.match(r'[\-\-]\s*\d+\s*[\-\-]$', line):
        return True
    # 已知的页眉噪音 (根据你的材料定制)
    noise_patterns = [
        "淡水河北側沿河平面道路工程",
        "環境影響評估報告書",
    ]
    for pattern in noise_patterns:
        if pattern in line and len(line) < 50:
            return True
    return False
```

处理对象	对象コード / 正規表現	除外されるノイズの具体例	処理の仕組みと目的
1. 空白行	if not line: (※事前に strip() を実行)	・ 純粋な空行 ・ スペースのみの行 ・ タブ(\\t)や改行(\\n)のみの行	意味を持たない空白をフィルタリングし、テキストのデータ構造を圧縮・最適化する。
2. 標準的なページ番号	r'^\\d+[\-\-]\\d+\$'	・ 1-1 ・ 5-12 ・ 10-2	行頭が数字で始まり、中間にハイフン（またはダッシュ）が入り、行末が数字で終わる独立した行を正規表現でマッチングして除外する。
3. 複合型のページ番号	r'^\\Ys*\\Yd+\\Ys*[頁页]\\Ys*共?\\Ys*\\d*\\Ys*[頁页]?\$'	・ 1頁 / 1 页 ・ 第1頁 共5頁 ・ 2 共 10 页	簡体字「页」と繁体字「頁」に両対応。「共」の文字や総ページ数はオプション（任意）とし、前後の空白(\\Ys*)も許容するフォールトトレランスの高い正規表現処理。
4. 独立したページ番号	r'^[\-\-]\\Ys*\\Yd+\\Ys*[\-\-]\$'	・ - 1 - ・ -10-	ページ下部によく配置される、前後がハイフンで対称的に囲まれ、中央に数字が配置されている行全体を判定して除外する。
5. 特定のヘッダー／フッター	pattern in line and len(line) < 50	・ 淡水河北側沿河平面道路工程 ・ 環境影響評估報告書	指定したキーワードが含まれ、かつ「行の文字数が50文字未満」である場合のみノイズと判定。本文中の同キーワードを含む長い文の誤削除（過剰適合）を防ぐ論理設計。

C
o
n
c
l
u
d
e
d

b
y

G
e
m
i
n
i

3.4 The result of text denoising

Before

第 34 页
=====

淡北道路二階環評專案小組會議 107.8.23初審
發言單 (發言人：環境法律人協會理事長張譽尹律師)

1、依開發行為環評作業準則之規定，開發單位應先查明開發行為基地是否位於環境敏感地區，基地不得位於相關法律所禁止開發利用之地區，位於相關法令所限制開發利用之地區，應不得違反該法令之限制規定。換言之，開發單位新北市政府環評主管機關需注意基地區位所受的其他法令限制。

2、系爭淡北道路基地緊鄰、密接或位於紅樹林自然保留區，淡水河流域重要濕地（國家級）。

3、依濕地保育法第20條規定，各級政府於重要濕地或已納入整體規劃管理之其他濕地及周邊環境辦理審核開發計劃或實施環評時，或其計劃有影響重要濕地之處者，應「先」徵詢內政部（濕地保育法中央主管機關）。依濕地保育法第27條，

p. 1

After

【第 34 页】

淡北道路二階環評專案小組會議 107.8.23初審發言單 (發言人：環境法律人協會理事長張譽尹律師)

1、依開發行為環評作業準則之規定，開發單位應先查明開發行為基地是否位於環境敏感地區，基地不得位於相關法律所禁止開發利用之地區，位於相關法令所限制開發利用之地區，應不得違反該法令之限制規定。換言之，開發單位新北市政府環評主管機關需注意基地區位所受的其他法令限制。

2、系爭淡北道路基地緊鄰、密接或位於紅樹林自然保留區，淡水河流域重要濕地（國家級）。

3、依濕地保育法第20條規定，各級政府於重要濕地或已納入整體規劃管理之其他濕地及周邊環境辦理審核開發計劃或實施環評時，或其計劃有影響重要濕地之處者，應「先」徵詢內政部（濕地保育法中央主管機關）。依濕地保育法第27條， p. 1

Mounted at /content/drive

検出された txt ファイル:

- ocr_結果.txt (382,281 バイト)
- ocr_結果test0511.txt (382,281 バイト)
- 淡北環評審查結論2020_vision版.txt (10,131 バイト)

原文の文字数: 179,243 文字

212 ページを認識

クリーニング完了!

原文: 179,243 文字

クリーニング後: 162,104 文字

削減率: 9.6%

保存先: /content/drive/MyDrive/ocr_結果_クリーニング版.txt

繁体字/簡体字変換: なし (繁体字を保持)

... Mounted at /content/drive
找到的 txt 文件:
- ocr_結果.txt (382,281 字节)
- ocr_結果test0511.txt (382,281 字节)
- 淡北環評審查結論2020_vision版.txt (10,131 字节)
原文长度: 179,243 字符
识别到 212 页

清洗完成!

原文: 179,243 字符

清洗后: 162,104 字符

减少: 9.6%

保存至: /content/drive/MyDrive/ocr_結果_清洗版.txt

繁简转换: 否 (保留繁体)

4. AI Purpose and Boundary

4 AI Purpose and Boundary

- AI's work: Repetitive and mechanical work. - “Data Cleaning”
- My work: Theoretical Work (Three level coding…….)
- Honestly report AI's usage in thesis.

Conclusion

The problem: Nvivo need pure TXT files but I have 3 types of PDF files.

Methodology: 1. Change them into TXT with 3 methods.

2. Clean them with Python.

Pay attention to Academic Ethics.

- Why Three Different Tools?

• Task	Best Tool	Reason
•		
• Extract text layer	pdftotext	Already digital
• OCR printed text	Cloud Vision	Cheap & accurate
• OCR handwriting	Gemini API	Multimodal understanding
• Clean noise	Python (rules)	Deterministic & free
• Code & interpret	Researcher	Theoretical sensitivity

- Principle:

- Match the tool to the nature of the task.

- Never overuse AI; never underuse it.

(This table was generated by Claude)

Thank You!